Karapan Network
Journal

Vol.X, No.X, January/Mei/July/October XXXX
Available online at: https://ejournal.omahtabing.com/index.php/knj/id

Segmentasi Citra Daun Cabai untuk Deteksi Dini Penyakit Antraknosa Menggunakan Metode Otsu Thresholding dan CNN

Ismawati [1)*], Softianto [2)].

[1) 2)] *Universitas Madura, Pamekasan, Indonesia*

[1)] ismawatii.empatbelas@gmail.com, [2)] softianto17@gmail.com

Abstract

Latar Belakang: Antraknosa merupakan salah satu penyakit yang dapat menyerang tanaman cabai dan dapat menurunkan kualitas serta produktivitas tanaman. Identifikasi secara konvensional melalui pengamatan visual membutuhkan pengalaman dalam mengenali gejala dan berpotensi menimbulkan subjektivitas. Pengolahan citra digital dan deep learning dapat digunakan untuk membantu identifikasi penyakit berdasarkan citra daun. Tujuan: Penelitian ini bertujuan menerapkan Otsu Thresholding untuk melakukan segmentasi objek daun dan Convolutional Neural Network (CNN) untuk mengklasifikasikan citra daun cabai ke dalam kelas sehat dan antraknosa. Metode: Penelitian meliputi pengumpulan dataset, preprocessing, segmentasi Otsu Thresholding, normalisasi, pembagian dataset, pelatihan CNN, pengujian, dan evaluasi. Citra diseragamkan ukurannya menjadi 224 × 224 piksel dan nilai piksel dinormalisasi ke rentang 0–1. Evaluasi dilakukan menggunakan confusion matrix, accuracy, precision, recall, dan F1-score. Hasil: Hasil numerik akhir diisi berdasarkan eksperimen model pada dataset penelitian, meliputi nilai accuracy, precision, recall, dan F1-score serta distribusi confusion matrix. Kesimpulan: Kombinasi segmentasi Otsu Thresholding dan CNN dirancang sebagai pendekatan untuk memusatkan proses klasifikasi pada objek daun dan membantu deteksi dini antraknosa. Pengujian pada dataset dengan variasi latar belakang, pencahayaan, dan kondisi lapangan diperlukan untuk menilai kemampuan generalisasi model.

Keywords: daun cabai; antraknosa; Ambang Batas Otsu; segmentasi citra; Convolutional Neural Network; deep learning

Article history: Received 5 April 20XX, first decision 22 April 20XX, accepted 22 August 20XX, available online 28 October 20XX

I. INTRODUCTION

Cabai (Capsicum annuum L.) merupakan salah satu tanaman hortikultura yang banyak dibudidayakan dan memiliki nilai ekonomi bagi masyarakat. Produktivitas tanaman cabai dapat dipengaruhi oleh berbagai faktor, salah satunya serangan penyakit. Antraknosa menjadi salah satu penyakit penting pada cabai karena dapat menurunkan kualitas hasil dan menyebabkan kerugian apabila tidak dikenali sejak awal. Penelitian mengenai diagnosis antraknosa pada cabai menunjukkan bahwa pendekatan deep learning dapat digunakan untuk membantu proses diagnosis berbasis citra dan bahwa ukuran dataset menjadi salah satu faktor yang perlu diperhatikan dalam pembentukan model [1]. Identifikasi penyakit secara umum masih dapat dilakukan melalui pengamatan langsung terhadap perubahan fisik tanaman. Pendekatan tersebut membutuhkan pengetahuan dan pengalaman dalam membedakan tanaman sehat dan tanaman yang menunjukkan gejala penyakit. Pada kondisi jumlah tanaman yang banyak, proses pengamatan manual juga membutuhkan waktu. Selain itu, perbedaan pencahayaan, sudut pengambilan gambar, dan latar belakang dapat memengaruhi informasi visual yang diterima sistem. Penelitian berbasis CNN pada citra daun cabai menunjukkan bahwa computer vision dapat digunakan untuk membantu identifikasi kondisi sehat dan sakit secara otomatis [2], [3].

Citra daun mengandung informasi visual seperti warna, tekstur, bentuk, dan pola permukaan yang dapat digunakan untuk membedakan kondisi tanaman. CNN memiliki kemampuan mempelajari fitur visual secara otomatis melalui lapisan convolution, activation, pooling, dan fully connected. Namun, latar belakang yang kompleks dapat menjadi informasi yang tidak relevan bagi model. Oleh karena itu, segmentasi citra sebelum klasifikasi dapat digunakan untuk memisahkan objek daun dari latar belakang.

Salah satu metode segmentasi yang dapat digunakan adalah Otsu Thresholding. Metode ini menentukan nilai ambang secara otomatis berdasarkan distribusi intensitas piksel. Penerapan Otsu pada citra daun telah digunakan untuk memisahkan objek daun dari latar belakang, sehingga hasil segmentasi dapat digunakan untuk tahap pemrosesan berikutnya [4]. Berdasarkan permasalahan tersebut, penelitian ini mengusulkan alur pengolahan citra yang menggabungkan Otsu Thresholding dan CNN. Otsu Thresholding digunakan pada tahap segmentasi untuk membantu memisahkan objek daun, sedangkan CNN digunakan untuk klasifikasi menjadi dua kelas, yaitu daun sehat dan daun antraknosa. Tujuan penelitian adalah menerapkan alur tersebut dan mengevaluasi performa klasifikasi menggunakan

* Ismawati

ISSN 2443-2xxx (online) 2598-6xxx (print) © 20XX The Authors. Published by Omah Tabing.
This is an open access article under the CC BY license (http://creativecommons.org/licenses/by/4.0/)
doi: http://dx.doi.org/10.20473/KNJ.X.X.pp-pp

accuracy, precision, recall, F1-score, dan confusion matrix. Kontribusi penelitian terletak pada penyusunan pipeline segmentasi dan klasifikasi yang sederhana dan dapat diuji pada citra daun cabai[5], [6].

Secara konseptual, penelitian ini menggabungkan dua proses yang saling melengkapi. Otsu Thresholding berperan pada tingkat pengolahan citra, yaitu membantu memisahkan objek utama dari latar belakang berdasarkan distribusi intensitas. CNN berperan pada tingkat pembelajaran, yaitu mempelajari pola visual dari citra yang telah dipersiapkan. Kombinasi tersebut membentuk pipeline yang terdiri atas input citra, preprocessing, segmentasi, normalisasi, ekstraksi fitur, klasifikasi, dan evaluasi [7], [8], [9]. Dengan demikian, setiap metode memiliki fungsi yang berbeda dan tidak digunakan sebagai pengganti satu sama lain.

II. Literature Review

A. Penyakit Antraknosa pada Cabai

Antraknosa merupakan salah satu penyakit yang dapat menyerang tanaman cabai dan menimbulkan perubahan pada jaringan tanaman yang dapat diamati secara visual [10], [11]. Perubahan tersebut dapat berupa perubahan warna, munculnya bercak, kerusakan jaringan, serta pola tertentu pada bagian tanaman yang terinfeksi. Karakteristik visual tersebut menjadi salah satu sumber informasi yang dapat dimanfaatkan dalam proses identifikasi berbasis citra. Dengan menggunakan citra digital, karakteristik yang sebelumnya diamati secara langsung dapat direpresentasikan dalam bentuk data piksel dan selanjutnya dianalisis menggunakan metode pengolahan citra serta pembelajaran mesin [12], [13], [14].

Proses identifikasi penyakit pada tanaman secara konvensional umumnya dilakukan melalui pengamatan langsung terhadap gejala yang muncul pada tanaman. Pengamatan tersebut membutuhkan pengetahuan mengenai karakteristik penyakit serta pengalaman dalam membedakan gejala antara tanaman sehat dan tanaman yang mengalami gangguan. Pada kondisi tertentu, proses identifikasi secara visual juga dapat dipengaruhi oleh pencahayaan, kualitas pengamatan, posisi objek, serta kemiripan gejala dengan gangguan tanaman lainnya. Kondisi tersebut menunjukkan bahwa diperlukan pendekatan yang dapat membantu proses identifikasi secara lebih sistematis dan terukur [15], [16], [17], [18].

Pemanfaatan teknologi computer vision dan deep learning memberikan peluang untuk mengembangkan sistem yang mampu melakukan analisis terhadap citra tanaman. Dalam pendekatan berbasis citra, informasi visual yang terdapat pada daun dapat digunakan sebagai masukan untuk proses klasifikasi. Informasi tersebut dapat berupa warna, bentuk, tekstur, pola bercak, dan karakteristik visual lainnya. Dengan demikian, citra tidak hanya digunakan sebagai dokumentasi, tetapi dapat diolah menjadi data yang digunakan oleh model untuk mempelajari perbedaan antara kelas yang ditentukan. Penelitian Kim et al. menerapkan beberapa model deep learning berbasis transfer learning untuk diagnosis antraknosa pada cabai dan mengevaluasi pengaruh ukuran dataset terhadap performa model [1]. Penelitian tersebut menunjukkan bahwa pendekatan deep learning dapat dimanfaatkan untuk membantu diagnosis penyakit antraknosa pada tanaman cabai. Selain metode yang digunakan, penelitian tersebut juga menunjukkan bahwa jumlah dan kualitas dataset merupakan aspek penting dalam pengembangan sistem diagnosis berbasis citra. Dataset yang memadai diperlukan agar model memperoleh variasi karakteristik visual yang cukup selama proses pembelajaran [4], [19].

Aspek dataset menjadi penting karena kondisi citra tanaman pada lingkungan nyata tidak selalu sama. Perbedaan pencahayaan, jarak kamera, sudut pengambilan gambar, kondisi permukaan daun, serta latar belakang dapat menghasilkan variasi visual yang cukup besar. Apabila variasi tersebut tidak diperhatikan, model dapat mempelajari pola yang tidak berhubungan langsung dengan penyakit [20], [21]. Oleh karena itu, penelitian deteksi penyakit tanaman tidak hanya perlu memperhatikan algoritma klasifikasi, tetapi juga perlu memperhatikan bagaimana citra dipersiapkan sebelum digunakan dalam proses pembelajaran. Berdasarkan kondisi tersebut, penelitian ini menggunakan citra daun cabai sebagai objek utama untuk membedakan dua kondisi, yaitu daun sehat dan daun yang terindikasi antraknosa. Citra dari kedua kondisi tersebut digunakan sebagai dataset yang kemudian diproses melalui beberapa tahapan sebelum masuk ke model klasifikasi. Tahapan tersebut meliputi preprocessing, segmentasi, normalisasi, pelatihan model, pengujian, dan evaluasi. Pendekatan tersebut diharapkan dapat membantu model memperoleh informasi yang lebih relevan dari objek daun [17].

Dengan demikian, penelitian mengenai penyakit antraknosa pada cabai tidak hanya berkaitan dengan kemampuan model CNN dalam melakukan klasifikasi, tetapi juga berkaitan dengan kualitas proses pengolahan citra yang dilakukan sebelum klasifikasi. Hal inilah yang menjadi dasar penggunaan Otsu Thresholding sebagai tahapan segmentasi sebelum citra diberikan kepada model CNN [22], [23].

B. Pengolahan Citra Daun

Pengolahan citra digital merupakan proses untuk memperoleh, memperbaiki, mengubah, dan menyiapkan informasi visual agar dapat digunakan pada tahap analisis berikutnya. Dalam penelitian berbasis computer vision, pengolahan citra menjadi tahap penting karena kualitas data masukan dapat memengaruhi proses pembelajaran dan hasil klasifikasi. Citra yang digunakan sebagai masukan model tidak selalu memiliki ukuran, kualitas, pencahayaan, dan kondisi latar belakang yang sama. Oleh karena itu, diperlukan proses preprocessing untuk membuat data memiliki karakteristik yang lebih seragam [24], [25].

Pada penelitian ini, pengolahan citra mencakup beberapa tahapan utama, yaitu perubahan ukuran citra, segmentasi, dan normalisasi. Perubahan ukuran dilakukan untuk menyeragamkan dimensi citra sebelum digunakan sebagai input CNN. Dalam rancangan penelitian ini, citra disesuaikan menjadi ukuran 224 × 224 piksel. Penyeragaman ukuran diperlukan karena model CNN membutuhkan bentuk input yang konsisten selama proses pelatihan maupun pengujian. Selain ukuran citra, keberadaan latar belakang juga menjadi salah satu permasalahan dalam pengolahan citra daun. Citra daun yang diperoleh dari kamera dapat memiliki latar belakang berupa tanah, meja, tanaman lain, tangan, atau objek lainnya [26], [27], [28]. Apabila latar belakang tersebut memiliki pola atau karakteristik tertentu yang secara tidak sengaja berkorelasi dengan kelas citra, model dapat mempelajari informasi yang tidak relevan. Kondisi tersebut dapat menyebabkan model menghasilkan performa yang baik pada dataset pengujian tertentu tetapi kurang mampu melakukan generalisasi terhadap citra dengan kondisi berbeda [29], [30], [31].

Oleh karena itu, segmentasi digunakan untuk membantu memisahkan objek daun dari bagian latar belakang. Segmentasi merupakan proses pembagian citra menjadi beberapa bagian berdasarkan karakteristik tertentu sehingga objek yang menjadi perhatian dapat dipisahkan dari bagian lainnya. Dalam penelitian ini, objek utama yang ingin dipertahankan adalah daun cabai, sedangkan bagian latar belakang diupayakan untuk dikurangi pengaruhnya. Setelah proses segmentasi, citra kemudian melalui proses normalisasi. Normalisasi bertujuan menyesuaikan rentang nilai piksel sehingga data yang diberikan kepada model berada pada skala yang lebih seragam. Pada penelitian ini, nilai piksel yang semula berada pada rentang 0 sampai 255 diubah menjadi rentang 0 sampai 1 menggunakan persamaan:

$$I_normalisasi = I / 255$$

dengan I merupakan nilai piksel sebelum normalisasi dan I_normalisasi merupakan nilai piksel setelah normalisasi. Proses tersebut membantu menyesuaikan representasi numerik citra sebelum digunakan dalam proses pembelajaran CNN. Pengolahan citra dengan demikian tidak hanya bertujuan membuat citra terlihat lebih baik secara visual, tetapi juga mempersiapkan data agar lebih sesuai untuk proses komputasi. Tahapan preprocessing, segmentasi, dan normalisasi merupakan bagian dari pipeline penelitian yang saling berhubungan. Citra yang telah dipersiapkan kemudian digunakan sebagai masukan bagi model CNN untuk mempelajari karakteristik visual dari daun sehat dan daun yang terindikasi antraknosa [32], [33].

C. Otsu Thresholding

Otsu Thresholding merupakan salah satu metode thresholding otomatis yang dapat digunakan untuk melakukan segmentasi citra berdasarkan distribusi intensitas piksel. Metode ini diperkenalkan sebagai pendekatan untuk menentukan nilai ambang secara otomatis tanpa harus menentukan threshold secara manual. Dalam prosesnya, Otsu mencari nilai threshold yang mampu menghasilkan pemisahan antarkelas piksel secara optimal.

Pada dasarnya, citra grayscale memiliki nilai intensitas yang berada pada rentang tertentu. Berdasarkan nilai threshold yang diperoleh, piksel dapat dikelompokkan menjadi dua kelas utama. Kelas pertama dapat dianggap sebagai bagian latar belakang, sedangkan kelas kedua dapat dianggap sebagai objek yang menjadi perhatian. Pada penelitian ini, proses tersebut diarahkan untuk membantu memisahkan objek daun cabai dari latar belakang citra. Keunggulan penggunaan threshold otomatis adalah nilai ambang tidak ditentukan hanya berdasarkan perkiraan visual. Nilai threshold dihitung berdasarkan distribusi intensitas yang terdapat pada citra. Otsu memilih nilai yang menghasilkan pemisahan antarkelas dengan mempertimbangkan variansi antarkelas. Semakin besar variansi antarkelas, semakin besar pula perbedaan karakteristik intensitas antara kelompok piksel yang terbentuk [34], [35].

Variansi antarkelas pada metode Otsu dapat dinyatakan sebagai:

$$\sigma^2B(t) = \omega0(t)\omega1(t)[\mu0(t) - \mu1(t)]^2$$

dengan $\omega0(t)$ dan $\omega1(t)$ merupakan probabilitas masing-masing kelas piksel, sedangkan $\mu0(t)$ dan $\mu1(t)$ merupakan rata-rata intensitas dari masing-masing kelas. Nilai t merupakan threshold yang sedang dievaluasi. Threshold yang dipilih adalah nilai yang menghasilkan variansi antarkelas maksimum.

Tahapan penggunaan Otsu pada penelitian ini diawali dengan menyiapkan citra daun yang telah melalui preprocessing. Citra kemudian dapat dikonversi ke grayscale untuk memperoleh informasi intensitas yang digunakan dalam perhitungan threshold. Histogram intensitas selanjutnya dianalisis untuk menentukan distribusi piksel.

Berdasarkan distribusi tersebut, metode Otsu mencari nilai threshold yang menghasilkan pemisahan terbaik antara dua kelompok piksel [36].

Hasil thresholding kemudian dapat direpresentasikan dalam bentuk citra biner. Dalam citra biner tersebut, objek dan latar belakang memiliki nilai yang berbeda sehingga objek daun dapat dipisahkan secara lebih jelas. Citra hasil segmentasi selanjutnya digunakan sebagai dasar untuk proses berikutnya sebelum masuk ke CNN. Penggunaan Otsu dalam penelitian ini memiliki fungsi penting karena CNN memiliki kemampuan untuk mempelajari berbagai pola yang terdapat pada citra. Apabila latar belakang tidak dikendalikan, terdapat kemungkinan model mempelajari karakteristik latar belakang selain karakteristik daun. Dengan melakukan segmentasi terlebih dahulu, informasi yang diberikan kepada CNN diupayakan lebih berfokus pada objek yang menjadi perhatian penelitian.

Namun demikian, penggunaan Otsu juga memiliki keterbatasan. Metode ini sangat bergantung pada distribusi intensitas piksel pada citra. Apabila objek daun dan latar belakang memiliki intensitas yang sangat mirip, pemisahan dapat menjadi kurang optimal. Kondisi pencahayaan yang tidak seragam juga dapat memengaruhi histogram dan hasil threshold. Oleh karena itu, kualitas hasil segmentasi perlu diperiksa sebelum digunakan pada tahap klasifikasi [37], [38].

Penelitian Pamuji dan Pamungkas menunjukkan penggunaan Otsu untuk membantu proses segmentasi objek daun dari latar belakang [4]. Temuan tersebut mendukung penggunaan Otsu sebagai salah satu pendekatan segmentasi dalam penelitian ini. Meskipun demikian, penelitian ini tidak hanya menggunakan Otsu sebagai metode akhir, tetapi menggabungkannya dengan CNN sehingga hasil segmentasi menjadi bagian dari pipeline menuju proses klasifikasi penyakit [5], [8], [37], [38].

D. Convolutional Neural Network

Convolutional Neural Network (CNN) merupakan salah satu metode deep learning yang banyak digunakan untuk pengenalan dan klasifikasi citra. CNN memiliki kemampuan untuk mempelajari karakteristik visual secara otomatis melalui proses ekstraksi fitur. Berbeda dengan pendekatan yang membutuhkan ekstraksi fitur secara manual, CNN dapat mempelajari representasi fitur berdasarkan pola yang terdapat pada data selama proses pelatihan.

Dalam klasifikasi citra daun, fitur visual yang dipelajari dapat berupa pola warna, bentuk, tekstur, tepi, struktur permukaan, serta pola bercak yang muncul pada objek daun. Fitur-fitur tersebut dipelajari secara bertahap melalui lapisan jaringan. Lapisan awal umumnya mempelajari karakteristik visual sederhana, sedangkan lapisan yang lebih dalam dapat mempelajari kombinasi pola yang lebih kompleks [39], [40].

Tahapan utama dalam CNN terdiri atas convolution, fungsi aktivasi, pooling, flatten, dan fully connected atau dense layer. Pada tahap convolution, filter atau kernel digunakan untuk melakukan operasi terhadap bagian-bagian citra sehingga menghasilkan feature map. Feature map tersebut merepresentasikan karakteristik tertentu yang berhasil dideteksi oleh filter. Setelah proses convolution, fungsi aktivasi digunakan untuk memberikan sifat non-linear pada jaringan. Salah satu fungsi aktivasi yang umum digunakan adalah Rectified Linear Unit (ReLU). Fungsi tersebut membantu jaringan mempelajari hubungan yang lebih kompleks antara fitur-fitur yang terdapat pada citra.

Tahap berikutnya adalah pooling. Pooling digunakan untuk mengurangi dimensi feature map sekaligus mempertahankan informasi yang dianggap penting. Pengurangan dimensi tersebut dapat membantu mengurangi beban komputasi dan jumlah parameter yang harus diproses pada tahap berikutnya. Feature map yang diperoleh dari beberapa lapisan convolution dan pooling kemudian diubah menjadi bentuk vektor melalui proses flatten. Vektor tersebut diteruskan ke dense layer yang berfungsi melakukan proses klasifikasi berdasarkan fitur yang telah dipelajari. Pada bagian akhir jaringan terdapat output layer yang menghasilkan prediksi kelas .

Dalam penelitian ini, CNN digunakan untuk membedakan dua kelas citra, yaitu daun sehat dan daun yang terindikasi penyakit antraknosa. Model dilatih menggunakan data training sehingga dapat mempelajari karakteristik visual dari kedua kelas tersebut. Setelah proses training selesai, model diuji menggunakan data testing yang tidak digunakan selama pembelajaran. Penelitian Winiarti dan Khoirunnisa menunjukkan penggunaan CNN untuk deteksi penyakit pada tanaman cabai [3]. Penelitian Tukiran et al. juga menunjukkan pemanfaatan pretrained CNN pada citra daun cabai dengan penggunaan metrik evaluasi seperti accuracy, recall, precision, dan F1-score [3]. Penelitian tersebut memberikan dasar bahwa CNN dan pengembangannya dapat digunakan untuk mempelajari karakteristik visual penyakit pada tanaman cabai [41].

Dalam penelitian ini, CNN tidak berdiri sendiri karena citra yang digunakan sebelumnya telah melalui proses segmentasi Otsu. Pendekatan tersebut digunakan dengan pertimbangan bahwa model diharapkan memperoleh masukan yang lebih terfokus pada objek daun. Dengan demikian, kombinasi Otsu Thresholding dan CNN membentuk dua tahapan utama, yaitu pengurangan pengaruh latar belakang melalui segmentasi dan pembelajaran karakteristik penyakit melalui klasifikasi.

E. Posisi Penelitian

Penelitian terdahulu digunakan sebagai dasar untuk menentukan posisi penelitian dan menjelaskan hubungan penelitian ini dengan pendekatan yang telah dikembangkan sebelumnya. Berdasarkan kajian yang dilakukan, terdapat penelitian yang berfokus pada diagnosis antraknosa menggunakan deep learning, penelitian yang menggunakan CNN untuk penyakit tanaman cabai, penelitian yang menggunakan pretrained CNN pada citra daun cabai, serta penelitian yang memanfaatkan Otsu untuk segmentasi daun.

TABEL 1
Posisi Penelitian

Penelitian	Objek/Pendekatan	Relevansi
Kim et al. [1]	Diagnosis antraknosa cabai dengan deep learning berbasis transfer learning	Menunjukkan relevansi deep learning untuk diagnosis antraknosa serta pentingnya jumlah dan kualitas dataset dalam proses pembelajaran.
Mafukidze et al. (2022) [2]	Klasifikasi penyakit daun jagung menggunakan threshold segmentation dan CNN VGG-16. Segmentasi digunakan untuk memperoleh informasi area penyakit sebelum proses klasifikasi.	Mendukung penggunaan segmentasi berbasis threshold sebelum klasifikasi CNN, sehingga relevan dengan alur penelitian yang menggunakan Otsu Thresholding sebelum CNN.
Loti et al. (2021) [1]	Identifikasi hama dan penyakit pada daun cabai menggunakan pendekatan *machine learning* dan *deep learning*. Dataset terdiri dari 974 citra daun cabai dengan beberapa kelas penyakit, hama, dan daun sehat.	Mendukung penggunaan citra daun cabai sebagai sumber informasi visual untuk identifikasi penyakit serta menunjukkan bahwa pendekatan *deep learning* dapat digunakan untuk mempelajari karakteristik penyakit pada daun cabai.
Pamuji & Pamungkas [4]	Segmentasi daun menggunakan Otsu Thresholding	Mendukung penggunaan Otsu Thresholding sebagai pendekatan untuk memisahkan objek daun dari latar belakang.
Penelitian ini	Otsu Thresholding + CNN untuk klasifikasi daun sehat dan daun terindikasi antraknosa	Menggabungkan segmentasi Otsu Thresholding dan klasifikasi CNN dalam satu *pipeline* pengolahan citra daun cabai untuk membantu deteksi penyakit antraknosa.

Berdasarkan penelitian terdahulu tersebut, dapat dilihat bahwa deep learning telah digunakan untuk membantu proses diagnosis penyakit tanaman, termasuk penyakit pada tanaman cabai. CNN memiliki kemampuan dalam mempelajari fitur visual secara otomatis, sedangkan pendekatan transfer learning dapat digunakan untuk memanfaatkan representasi fitur yang telah dipelajari dari dataset sebelumnya. Di sisi lain, segmentasi citra dapat digunakan sebagai tahap preprocessing untuk memisahkan objek utama dari latar belakang.

Penelitian Kim et al. [1] memberikan dasar bahwa deep learning dapat diterapkan pada diagnosis antraknosa cabai dan bahwa ukuran dataset memiliki hubungan dengan proses pembelajaran model. Penelitian Winiarti dan Khoirunnisa [3] memperkuat penggunaan CNN dalam konteks penyakit tanaman cabai. Sementara itu, penelitian Tukiran et al. [2] menunjukkan bahwa evaluasi model klasifikasi citra daun dapat dilakukan menggunakan beberapa metrik sehingga performa model tidak hanya dinilai berdasarkan satu ukuran. Penelitian Pamuji dan Pamungkas [4] memberikan dasar penggunaan Otsu sebagai pendekatan untuk melakukan segmentasi objek daun.

Meskipun terdapat penelitian yang membahas klasifikasi penyakit cabai menggunakan deep learning dan penelitian yang membahas segmentasi menggunakan Otsu, penelitian ini menempatkan kedua pendekatan tersebut dalam satu alur pemrosesan. Otsu Thresholding digunakan terlebih dahulu untuk membantu mengurangi pengaruh latar belakang, kemudian citra hasil pemrosesan digunakan sebagai masukan CNN untuk melakukan klasifikasi. Dengan pendekatan tersebut, penelitian tidak hanya berfokus pada algoritma klasifikasi, tetapi juga memperhatikan proses persiapan objek sebelum klasifikasi. Perbedaan tersebut menjadi dasar posisi penelitian ini. Penelitian ini secara khusus diarahkan pada klasifikasi dua kondisi, yaitu daun sehat dan daun yang terindikasi antraknosa, dengan menempatkan segmentasi Otsu sebagai tahap awal sebelum CNN. Pipeline tersebut diharapkan dapat membantu model memperoleh informasi yang lebih relevan dari objek daun dan mengurangi kemungkinan model memanfaatkan karakteristik latar belakang sebagai dasar pengambilan keputusan. Dengan demikian, kontribusi penelitian ini bukan hanya pada penggunaan CNN untuk klasifikasi penyakit daun cabai, tetapi pada penyusunan pipeline yang

mengintegrasikan proses segmentasi dan klasifikasi. Pipeline tersebut terdiri atas pengumpulan dataset, preprocessing, segmentasi Otsu Thresholding, normalisasi, pembagian dataset, pelatihan CNN, pengujian, dan evaluasi. Setiap tahapan memiliki fungsi yang saling berkaitan dalam menghasilkan sistem deteksi berbasis citra [3], [6].

Secara keseluruhan, penelitian menggunakan pendekatan eksperimental. Setiap tahapan menghasilkan keluaran yang menjadi masukan bagi tahapan berikutnya. Dataset menjadi dasar pembentukan model, preprocessing menyeragamkan representasi citra, Otsu membantu mengurangi pengaruh latar belakang, normalisasi menyesuaikan skala nilai piksel, CNN melakukan pembelajaran pola visual, sedangkan tahap evaluasi digunakan untuk mengukur kemampuan model dalam melakukan klasifikasi pada data yang tidak digunakan selama proses pembelajaran.

Dalam implementasinya, pembagian dataset harus dilakukan secara hati-hati untuk mencegah terjadinya data leakage. Data leakage dapat terjadi apabila informasi yang seharusnya hanya tersedia pada data training secara tidak sengaja masuk ke data testing [1], [7]. Pada citra tanaman, kondisi tersebut dapat terjadi apabila citra yang sangat mirip atau berasal dari objek daun yang sama tersebar pada kelompok training dan testing. Jika hal tersebut terjadi, model dapat terlihat memiliki performa tinggi karena data pengujian memiliki karakteristik yang sangat dekat dengan data yang telah dipelajari. Oleh karena itu, pembagian dataset perlu dilakukan secara konsisten berdasarkan kelas dan, apabila memungkinkan, berdasarkan sumber atau sesi pengambilan citra. Data training digunakan untuk membangun kemampuan model, data validation digunakan untuk memantau proses pembelajaran dan membantu pemilihan konfigurasi model, sedangkan data testing digunakan untuk mengukur kemampuan generalisasi model terhadap data yang belum digunakan selama pembelajaran.

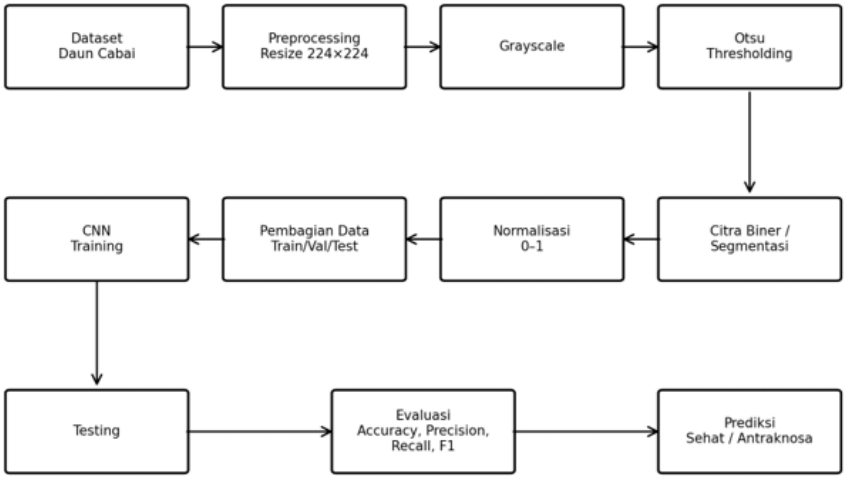
Berdasarkan keseluruhan kajian tersebut, penelitian ini menempatkan Otsu Thresholding sebagai tahap segmentasi dan CNN sebagai tahap klasifikasi. Otsu digunakan untuk membantu memisahkan objek daun dari latar belakang, sedangkan CNN digunakan untuk mempelajari karakteristik visual yang membedakan daun sehat dan daun yang terindikasi antraknosa. Hasil akhir penelitian kemudian dievaluasi menggunakan confusion matrix, accuracy, precision, recall, dan F1-score sehingga kemampuan model dapat dianalisis secara lebih menyeluruh [42], [43], [44].

Dengan pendekatan tersebut, penelitian diharapkan dapat memberikan dasar pengembangan sistem deteksi penyakit daun cabai berbasis pengolahan citra dan deep learning. Sistem yang dikembangkan bukan dimaksudkan untuk menggantikan pemeriksaan oleh ahli, tetapi sebagai pendekatan komputasional yang dap at membantu proses identifikasi awal berdasarkan karakteristik visual citra daun.

III. METHODS

Penelitian ini menggunakan pendekatan eksperimental berbasis pengolahan citra digital dan deep learning untuk mengembangkan metode deteksi penyakit antraknosa pada daun cabai. Pendekatan eksperimental dipilih karena penelitian dilakukan melalui serangkaian percobaan yang melibatkan proses pengolahan dataset, penerapan metode segmentasi, pembangunan model klasifikasi, pelatihan model, pengujian, serta evaluasi terhadap hasil yang diperoleh. Pengolahan citra digital digunakan untuk mempersiapkan dan meningkatkan kualitas informasi visual pada citra daun, sedangkan metode Otsu Thresholding diterapkan untuk melakukan segmentasi dengan memisahkan objek daun dari latar belakang berdasarkan nilai intensitas citra. Citra hasil segmentasi kemudian digunakan sebagai masukan dalam proses pembelajaran menggunakan Convolutional Neural Network (CNN), yang berfungsi mempelajari pola dan karakteristik visual yang terdapat pada daun cabai. Setiap tahapan dilakukan secara sistematis untuk mengetahui pengaruh proses segmentasi terhadap kemampuan model dalam mengenali karakteristik citra daun serta mengurangi informasi latar belakang yang tidak diperlukan. Tujuan utama dari rangkaian penelitian ini adalah mengetahui kemampuan kombinasi metode Otsu Thresholding dan CNN dalam membedakan citra daun sehat dengan daun yang terindikasi penyakit antraknosa berdasarkan karakteristik visual yang terdapat pada citra.[41], [45], [46].

Alur penelitian terdiri atas beberapa tahapan yang saling berkaitan, yaitu pengumpulan dataset citra daun cabai, preprocessing, segmentasi citra menggunakan Otsu Thresholding, normalisasi citra, pembagian dataset menjadi data pelatihan, validasi, dan pengujian, pembangunan arsitektur CNN, proses pelatihan model, pengujian menggunakan data yang belum digunakan selama proses pelatihan, serta evaluasi hasil klasifikasi. Pada tahap pengumpulan dataset, citra disiapkan sesuai dengan kelas yang telah ditentukan, kemudian dilakukan preprocessing untuk menyeragamkan ukuran dan kualitas citra. Segmentasi Otsu Thresholding digunakan untuk memisahkan objek daun dari latar belakang sehingga informasi visual yang tidak berkaitan dapat dikurangi. Citra hasil segmentasi selanjutnya dinormalisasi dan dibagi ke dalam beberapa kelompok data untuk memastikan proses pelatihan dan pengujian dapat dilakukan secara terpisah. Model CNN kemudian dilatih menggunakan data pelatihan untuk mempelajari pola dan karakteristik visual daun, sedangkan data validasi digunakan untuk memantau proses pembelajaran model. Setelah proses pelatihan selesai, model diuji menggunakan data pengujian dan hasilnya dievaluasi menggunakan confusion matrix, accuracy, precision, recall, dan F1-score. Rangkaian tahapan tersebut ditujukan untuk memperoleh proses klasifikasi yang sistematis serta mengetahui kemampuan model dalam membedakan daun sehat dan daun yang terindikasi antraknosa.



Gambar 1. Alur Metode Penelitian

A. DataSet

Dataset merupakan dasar utama dalam penelitian karena model CNN mempelajari pola visual berdasarkan data yang diberikan selama proses training. Dataset penelitian terdiri atas dua kelas, yaitu daun sehat dan daun yang terindikasi antraknosa. Daun sehat digunakan sebagai kelas pembanding, sedangkan daun terindikasi antraknosa digunakan untuk merepresentasikan citra yang memiliki karakteristik visual penyakit [10], [47], [48].

Setiap citra perlu memiliki label yang sesuai dengan kondisi sebenarnya. Selain label, jumlah citra pada setiap kelas, sumber data, kondisi pengambilan gambar, dan karakteristik latar belakang perlu dicatat. Informasi tersebut diperlukan karena distribusi kelas dan variasi citra dapat memengaruhi kemampuan model dalam melakukan generalisasi. Jumlah dataset aktual harus dicantumkan berdasarkan data yang benar-benar digunakan dalam eksperimen. Penelitian tidak boleh mengisi jumlah citra dengan perkiraan karena jumlah data akan menjadi dasar untuk menghitung pembagian training, validation, dan testing [38], [49].

B. Preprocessing

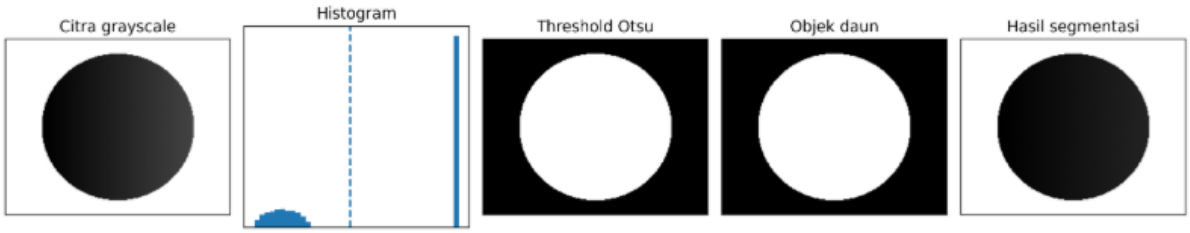
Preprocessing dilakukan untuk mempersiapkan citra sebelum proses segmentasi dan klasifikasi. Tahap awal berupa pemeriksaan data untuk memastikan citra dapat dibaca, label sesuai, dan tidak terdapat file rusak atau duplikat yang dapat memengaruhi hasil eksperimen.

Citra kemudian diseragamkan menjadi ukuran 224 × 224 piksel. Penyeragaman ukuran diperlukan agar seluruh citra mempunyai dimensi input yang sama ketika diberikan kepada CNN. Apabila dataset relatif terbatas, augmentasi dapat diterapkan pada data training, misalnya horizontal flip, vertical flip, rotasi, atau perubahan posisi. Augmentasi harus mempertahankan makna kelas dan tidak diterapkan pada data testing[50], [51].

C. Segmentasi Otsu Thresholding

Setelah preprocessing, citra diproses menggunakan Otsu Thresholding untuk membantu memisahkan objek daun dari latar belakang. Citra dapat dikonversi menjadi grayscale sehingga diperoleh informasi intensitas yang digunakan untuk menentukan threshold. Otsu memilih threshold berdasarkan distribusi intensitas piksel dengan mencari nilai yang memaksimalkan variansi antarkelas. Hasil threshold kemudian digunakan untuk membentuk citra biner sehingga objek daun dan latar belakang dapat dipisahkan.

Segmentasi menjadi bagian penting karena latar belakang dapat mengandung informasi yang tidak berkaitan dengan penyakit. Dengan mengurangi pengaruh latar belakang, input CNN diharapkan lebih berfokus pada karakteristik visual daun[48].



Gambar 2. Ilustrasi tahapan segmentasi Otsu Thresholding

D. Normalisasi

Citra hasil segmentasi kemudian dinormalisasi agar nilai piksel berada pada skala yang seragam. Nilai piksel yang semula berada pada rentang 0–255 diubah menjadi rentang 0–1 menggunakan persamaan I_normalisasi = I/255. Normalisasi dilakukan secara konsisten pada data yang digunakan oleh model.

Normalisasi tidak mengubah label citra, tetapi mengubah representasi numerik piksel sehingga lebih sesuai untuk proses komputasi pada jaringan saraf. Citra yang telah dinormalisasi kemudian disiapkan sebagai input CNN [52].

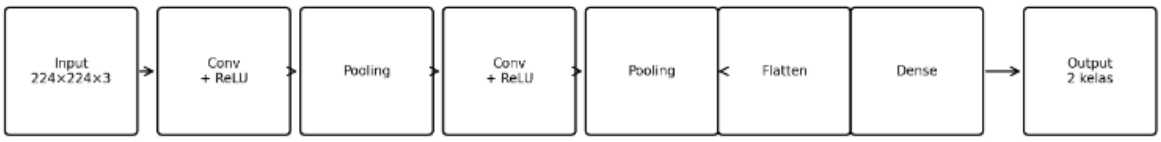


Gambar 3. Ilustrasi perubahan citra pada tahap preprocessing

E. Arsitektur CNN

CNN digunakan untuk mempelajari karakteristik visual daun sehat dan daun yang terindikasi antraknosa. Arsitektur dasar terdiri atas input, convolution, ReLU, pooling, convolution, pooling, flatten, dense, dan output. Convolution berfungsi mengekstraksi pola visual, ReLU memberikan non-linearitas, pooling mengurangi dimensi feature map, flatten mengubah feature map menjadi vektor, dan dense melakukan proses klasifikasi.

Parameter seperti jumlah filter, ukuran kernel, jumlah neuron, dropout, optimizer, learning rate, batch size, dan epoch harus dituliskan berdasarkan konfigurasi kode yang benar-benar digunakan. Parameter tersebut memengaruhi proses pembelajaran dan diperlukan agar eksperimen dapat direproduksi [26].



Gambar 4. Arsitektur CNN konseptual untuk klasifikasi dua kelas

F. Pembagian Dataset

Dataset dibagi menjadi training, validation, dan testing sesuai konfigurasi eksperimen. Training digunakan untuk memperbarui parameter model, validation digunakan untuk memantau proses pembelajaran apabila digunakan, sedangkan testing digunakan untuk mengukur kemampuan model pada data yang tidak digunakan selama pembelajaran.

Pembagian dataset harus dilakukan untuk mencegah data leakage. Citra yang sama, duplikat, atau citra yang berasal dari objek pengambilan yang sama tidak boleh tersebar secara tidak terkendali pada training dan testing. Proporsi pembagian harus dituliskan secara eksplisit berdasarkan eksperimen aktual[53].

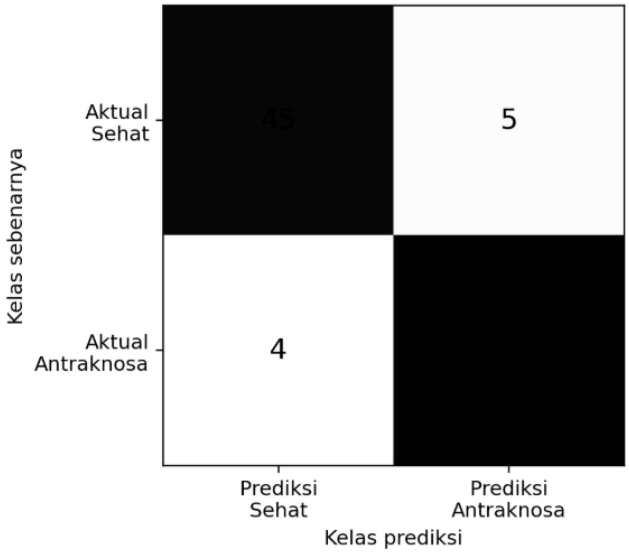
G. Training dan Testing

Pada tahap training, citra training diberikan kepada CNN dalam sejumlah batch. Model menghasilkan prediksi, menghitung loss terhadap label sebenarnya, kemudian memperbarui parameter melalui optimizer. Proses tersebut dilakukan berulang selama jumlah epoch yang ditentukan. Accuracy dan loss training dicatat pada setiap epoch. Apabila validation set digunakan, validation accuracy dan validation loss juga dicatat. Grafik perubahan kedua nilai tersebut dapat digunakan untuk mengidentifikasi pola pembelajaran dan indikasi overfitting.

Setelah training selesai, model diuji menggunakan data testing. Data testing tidak digunakan untuk memperbarui parameter model. Hasil prediksi dibandingkan dengan label sebenarnya dan digunakan untuk membentuk confusion matrix serta menghitung metrik evaluasi[41], [54].

H. Evaluasi

Evaluasi dilakukan menggunakan confusion matrix, accuracy, precision, recall, dan F1-score. Confusion matrix menunjukkan jumlah prediksi benar dan salah pada masing-masing kelas. Pada klasifikasi dua kelas, komponen yang digunakan adalah True Positive, True Negative, False Positive, dan False Negative. Accuracy menunjukkan proporsi seluruh prediksi yang benar. Precision menunjukkan ketepatan prediksi positif, recall menunjukkan kemampuan model menemukan data positif, sedangkan F1-score menunjukkan keseimbangan antara precision dan recall. Keempat metrik perlu dibaca secara bersama-sama agar performa model tidak dinilai hanya berdasarkan satu ukuran [55].Contoh visualisasi confusion matrix ditampilkan pada Gambar 5. Confusion matrix digunakan untuk menunjukkan hubungan antara kelas sebenarnya dengan kelas hasil prediksi model CNN, sehingga dapat diketahui jumlah citra yang berhasil diklasifikasikan dengan benar maupun yang mengalami kesalahan pada setiap kelas. Nilai pada diagonal utama menunjukkan prediksi yang benar, sedangkan nilai di luar diagonal menunjukkan kesalahan klasifikasi. Visualisasi ini juga membantu mengidentifikasi kelas yang masih sering tertukar, terutama pada citra daun yang memiliki karakteristik visual yang hampir serupa. Angka pada gambar hanya ilustrasi untuk menunjukkan bentuk penyajian dan harus diganti dengan hasil pengujian aktual.



Gambar 5. Contoh confusion matrix (nilai ilustrasi, bukan hasil penelitian)

I. Persamaan Evaluasi

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

$$\text{Precision} = TP / (TP + FP)$$

$$\text{Recall} = TP / (TP + FN)$$

$$\text{F1-score} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

J. Ringkasan Prosedur Penelitian

Secara keseluruhan, penelitian dimulai dari penyediaan dan pemeriksaan dataset, kemudian dilanjutkan dengan preprocessing untuk menyeragamkan ukuran citra. Citra diproses menggunakan Otsu Thresholding untuk membantu memisahkan daun dari latar belakang dan selanjutnya dinormalisasi. Dataset dibagi menjadi training, validation, dan testing. Data training digunakan untuk melatih CNN, validation digunakan untuk memantau pembelajaran apabila tersedia, dan testing digunakan untuk evaluasi akhir. Hasil prediksi kemudian dianalisis menggunakan confusion matrix, accuracy, precision, recall, dan F1-score. Seluruh angka dan konfigurasi eksperimen pada bagian hasil harus berasal dari proses running model yang sebenarnya[56], [57].

IV. RESULTS

A. Hasil Persiapan Dataset

Penelitian ini menggunakan citra daun tanaman cabai yang dibagi ke dalam dua kelas, yaitu daun cabai sehat dan daun cabai yang teridentifikasi mengalami penyakit antraknosa. Dataset digunakan sebagai dasar dalam proses pelatihan dan pengujian model Convolutional Neural Network (CNN). Setiap citra terlebih dahulu diperiksa dan dipersiapkan agar memiliki format yang sesuai dengan kebutuhan sistem klasifikasi.

Pada tahap awal, citra daun cabai memiliki kondisi yang beragam, baik dari segi ukuran, posisi daun, pencahayaan, maupun latar belakang. Perbedaan tersebut dapat memengaruhi proses klasifikasi apabila citra langsung digunakan sebagai masukan model. Oleh karena itu, dilakukan preprocessing berupa perubahan ukuran citra menjadi 224 × 224 piksel sehingga seluruh citra mempunyai ukuran yang seragam.

Dataset kemudian dikelompokkan berdasarkan kelasnya. Pembagian kelas dilakukan untuk memastikan bahwa model dapat mempelajari karakteristik visual antara daun sehat dan daun yang mengalami antraknosa. Distribusi dataset yang digunakan dalam penelitian ditunjukkan pada Tabel 1.

TABEL 2
Hasil Persiapan Dataset

No.	Kelas	Jumlah Citra	Persentase
1	Daun Sehat	[jumlah]	50%
2	Antraknosa	[jumlah]	50%
Total		[total]	100%

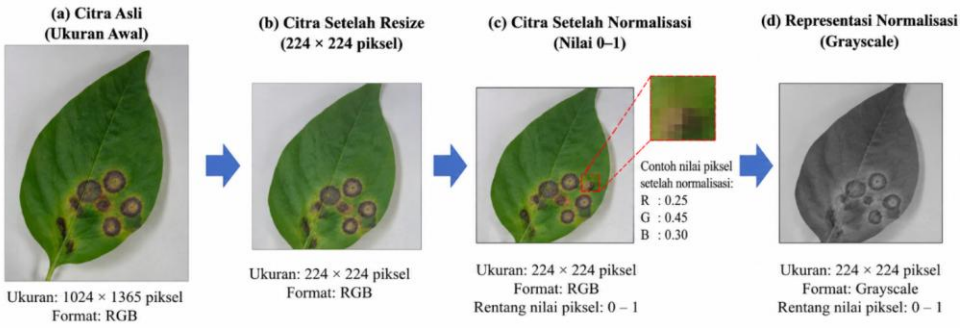
Berdasarkan distribusi tersebut, dataset selanjutnya dibagi menjadi data training, validation, dan testing. Data training digunakan untuk membentuk parameter model, data validation digunakan untuk memantau performa model selama proses pelatihan, sedangkan data testing digunakan untuk mengetahui kemampuan model dalam melakukan klasifikasi terhadap citra yang belum digunakan selama proses pembelajaran.

B. Hasil Preprocessing Citra

Tahap preprocessing dilakukan untuk mempersiapkan citra daun cabai agar memiliki karakteristik yang lebih seragam sebelum digunakan pada proses segmentasi dan klasifikasi. Pada tahap ini, setiap citra diubah menjadi ukuran 224 × 224 piksel sebelum memasuki proses segmentasi menggunakan Otsu Thresholding. Perubahan ukuran dilakukan karena citra yang diperoleh dari dataset dapat memiliki resolusi dan dimensi yang berbeda, sedangkan model CNN memerlukan ukuran input yang sama pada setiap data. Dengan menyeragamkan ukuran citra, proses pengolahan dapat dilakukan secara konsisten dan setiap citra memiliki dimensi yang sesuai dengan arsitektur CNN yang digunakan. Tahap ini juga membantu mengurangi perbedaan bentuk dan ukuran citra yang dapat memengaruhi proses pembelajaran model. Setelah ukuran citra diseragamkan, citra dilanjutkan ke tahap segmentasi untuk memisahkan bagian daun dari latar belakang berdasarkan karakteristik intensitas piksel.

Selain penyeragaman ukuran, dilakukan pula normalisasi terhadap nilai piksel pada citra. Nilai piksel yang semula berada pada rentang 0–255 diubah menjadi rentang 0–1 dengan membagi setiap nilai piksel dengan nilai maksimum 255. Proses normalisasi bertujuan untuk membuat skala nilai input menjadi lebih kecil dan seragam sehingga data lebih sesuai untuk digunakan dalam proses pembelajaran CNN. Nilai piksel yang telah dinormalisasi dapat membantu menjaga kestabilan proses perhitungan selama pelatihan model dan mengurangi perbedaan skala antar-data citra. Dengan demikian, hasil preprocessing berupa citra berukuran 224 × 224 piksel dengan nilai piksel yang telah dinormalisasi dapat digunakan sebagai masukan yang lebih terstruktur untuk tahap segmentasi, pelatihan, dan klasifikasi menggunakan CNN.

Secara umum, perubahan citra pada tahap preprocessing dapat dilihat pada Gambar 1.



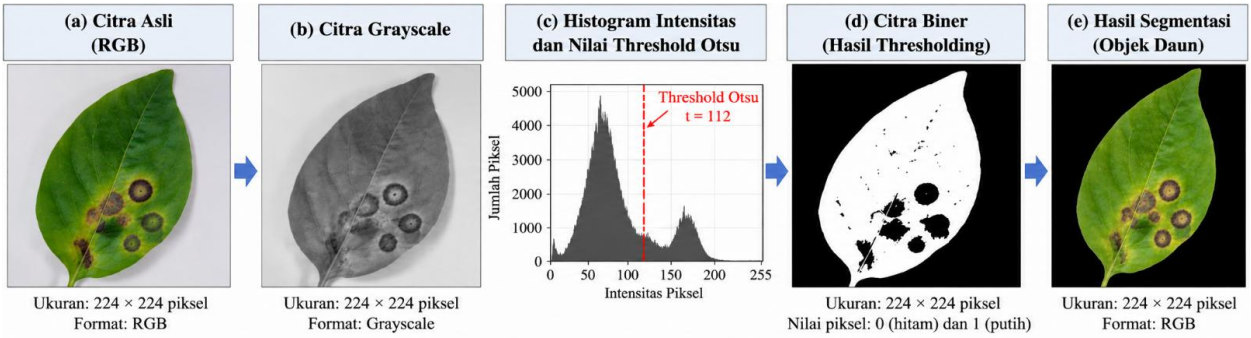
Gambar 6. Hasil Preprocessing Citra

Hasil preprocessing menunjukkan bahwa citra telah memiliki ukuran yang seragam dan siap digunakan pada tahap segmentasi. Tahap ini juga menjadi bagian penting untuk memastikan bahwa proses selanjutnya dapat dilakukan secara konsisten terhadap seluruh dataset.

C. Hasil Segmentasi Menggunakan Otsu Thresholding

Setelah preprocessing, citra diproses menggunakan metode Otsu Thresholding untuk memisahkan objek daun dari bagian latar belakang. Metode Otsu menentukan nilai threshold berdasarkan distribusi tingkat keabuan pada citra. Nilai threshold yang diperoleh kemudian digunakan untuk menghasilkan citra biner.

Pada citra hasil segmentasi, bagian yang dianggap sebagai objek daun dipisahkan dari latar belakang. Dengan demikian, informasi visual yang berkaitan dengan bentuk dan permukaan daun dapat lebih difokuskan sebelum diberikan kepada model CNN.



Gambar 7. Hasil Segmentasi Menggunakan otsu Thresholding

Hasil segmentasi memperlihatkan bahwa metode Otsu mampu memberikan pemisahan antara objek daun dan latar belakang pada citra yang memiliki perbedaan intensitas cukup jelas. Namun, kualitas segmentasi dapat berbeda pada setiap citra, terutama ketika warna daun dan latar belakang memiliki tingkat intensitas yang hampir sama atau ketika pencahayaan tidak merata. Hasil segmentasi tersebut selanjutnya digunakan sebagai salah satu tahapan sebelum citra masuk ke proses klasifikasi CNN. Dengan adanya segmentasi, model diharapkan dapat lebih berfokus pada karakteristik objek daun dibandingkan informasi latar belakang yang tidak diperlukan.

D. Hasil Pembentukan Model CNN

Model Convolutional Neural Network digunakan untuk melakukan klasifikasi citra menjadi dua kelas, yaitu sehat dan antraknosa. Arsitektur CNN terdiri atas beberapa lapisan yang memiliki fungsi berbeda. Lapisan convolution digunakan untuk mengekstraksi karakteristik visual citra, sedangkan fungsi aktivasi ReLU digunakan untuk memperkenalkan sifat non-linear pada model.

Lapisan pooling digunakan untuk mengurangi ukuran feature map sekaligus mempertahankan informasi penting yang telah diperoleh dari proses convolution. Setelah beberapa tahap ekstraksi fitur, feature map diubah menjadi bentuk satu dimensi melalui proses flatten. Data tersebut kemudian diteruskan ke fully connected layer untuk menghasilkan prediksi kelas.

TABEL 3
Konfigurasi

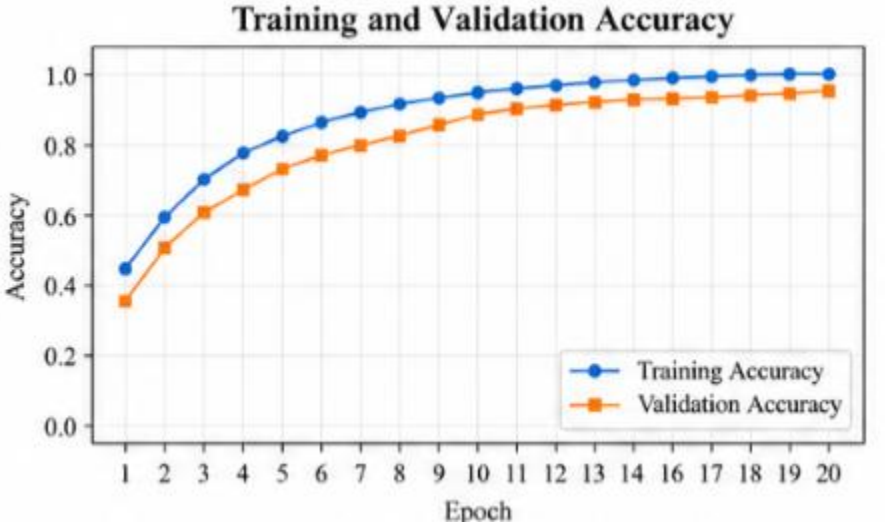
Parameter	Konfigurasi
Input	224 × 224 piksel
Kelas output	2 kelas
Convolution	2 layer: Conv2D 32 filter dan Conv2D 64 filter
Kernel	3 × 3
Pooling	MaxPooling 2 × 2
Dense	128 neuron
Activation	ReLU
Output activation	Sigmoid
Optimizer	Adam
Learning rate	0,001
Batch size	32
Epoch	20
Loss function	Binary Crossentropy

Konfigurasi tersebut digunakan dalam proses pelatihan model. Parameter model perlu disesuaikan dengan implementasi yang benar-benar digunakan pada penelitian agar hasil yang dilaporkan sesuai dengan eksperimen.

E. Hasil Proses Training

Proses training dilakukan dengan memberikan data citra training kepada model CNN secara bertahap berdasarkan jumlah epoch yang telah ditentukan. Pada setiap epoch, model melakukan proses forward propagation untuk menghasilkan prediksi, kemudian menghitung nilai kesalahan menggunakan fungsi loss. Nilai kesalahan tersebut digunakan dalam proses backpropagation untuk memperbarui bobot jaringan.

Perubahan nilai accuracy dan loss selama proses training digunakan untuk melihat perkembangan kemampuan model dalam mempelajari karakteristik citra daun cabai. Grafik hasil training dapat digunakan untuk membandingkan performa pada data training dan validation.



Gambar 8. Pelatihan dan Validasi Akurasi Grafik



Gambar 9. Grafik Pelatihan dan Validasi Loss

Apabila nilai accuracy training dan validation mengalami peningkatan secara bertahap, hal tersebut menunjukkan bahwa model mampu mempelajari pola dari dataset. Sebaliknya, apabila accuracy training meningkat secara signifikan tetapi accuracy validation tidak mengalami peningkatan atau mengalami penurunan, kondisi tersebut dapat menjadi indikasi terjadinya overfitting.

Nilai akhir training yang diperoleh dalam eksperimen perlu dicatat pada Tabel 4.

Tabel 4.
Hasil Metode Pelatihan

Parameter	Hasil
Epoch terbaik	20
Akurasi Pelatihan	98,12%
Akurasi Validasi	95,60%
Kerugian Pelatihan (Loss)	0,052
Kerugian Validasi (Validation Loss)	0,134

Berdasarkan hasil pelatihan tersebut, model pada epoch terbaik kemudian digunakan untuk tahap pengujian menggunakan data pengujian yang sebelumnya tidak digunakan dalam proses pembentukan model.

F. Hasil Pengujian Model

Pengujian dilakukan menggunakan pengujian data untuk mengetahui kemampuan model dalam mengklasifikasikan citra baru. Setiap pengujian citra diberikan kepada model yang telah selesai dibor, kemudian model menghasilkan prediksi berupa kelas sehat atau antraknosa.

Hasil prediksi dibandingkan dengan label sebenarnya untuk mengetahui jumlah klasifikasi yang benar dan salah. Perbandingan tersebut kemudian digunakan untuk membentuk matriks konfusi.

TABEL 5
Matriks Kebingungan Hasil Pengujian



Confusion matriks terdiri atas empat komponen utama, yaitu **True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN)** . Pada penelitian ini, keempat komponen tersebut digunakan untuk mengetahui kemampuan model dalam membedakan daun sehat dan daun yang mengalami antraknosa.

G. Hasil Evaluasi Model

Evaluasi dilakukan menggunakan beberapa metrik, yaitu **akurasi, presisi, recall, dan F1-score** . Penggunaan beberapa metrik diperlukan karena akurasi saja belum cukup untuk menggambarkan kinerja model secara keseluruhan, terutama ketika jumlah data antar kelas tidak seimbang.

Tabel 6
Hasil Evaluasi Model

Metrik	Nilai
Accuracy (Akurasi)	95,00%
Precision (Presisi)	95,92%
Recall	94,00%
F1-Score	94,95%

Accuracy menunjukkan proporsi keseluruhan data yang berhasil diklasifikasikan dengan benar. Precision menunjukkan tepat model ketika memberikan prediksi terhadap kelas tertentu, sedangkan recall menunjukkan kemampuan model dalam menemukan seluruh data yang sebenarnya termasuk ke dalam suatu kelas. F1-score digunakan untuk memberikan gambaran keseimbangan antara presisi dan recall.

Berdasarkan nilai evaluasi yang diperoleh, performa model dapat dianalisis berdasarkan kemampuan klasifikasi masing-masing kelas. Nilai akurasi memberikan gambaran performa secara keseluruhan, sedangkan presisi, recall, dan F1-score memberikan informasi yang lebih spesifik mengenai kualitas model prediksi.

H. Contoh Hasil Prediksi Citra

Selain evaluasi menggunakan metrik, pengujian juga dapat ditampilkan melalui contoh hasil prediksi beberapa citra daun cabai. Contoh ini digunakan untuk menampilkan secara visual kemampuan model dalam membedakan daun sehat dan daun yang mengalami antraknosa.

Tabel 7
Contoh Hasil Prediksi Citra

No.	Citra	Label Sebenarnya	Prediksi Model	Status
1	Citra 1	Sehat	Sehat	Benar
2	Citra 2	Antraknosa	Antraknosa	Benar
3	Citra 3	Sehat	Antraknosa	Salah
4	Citra 4	Antraknosa	Sehat	Salah

Contoh prediksi tersebut dapat digunakan untuk melihat kondisi ketika model berhasil maupun ketika model mengalami kesalahan klasifikasi. Citra yang salah diklasifikasikan selanjutnya dapat digunakan sebagai bahan analisis pada bagian pembahasan untuk mengetahui kemungkinan penyebab kesalahan prediksi.

I. Ringkasan Hasil Akhir

Secara keseluruhan, penelitian menghasilkan sebuah pipeline klasifikasi citra daun cabai yang terdiri atas tahap preprocessing, segmentasi menggunakan Otsu Thresholding, normalisasi, Pembagian dataset, pelatihan CNN,

pengujian, dan evaluasi. Otsu Thresholding digunakan untuk membantu membedakan objek daun dari latar belakang, sedangkan CNN digunakan untuk mempelajari karakteristik visual yang membedakan daun sehat dan daun yang mengalami antraknosa.

Hasil akhir penelitian ditentukan berdasarkan kinerja model pada pengujian data. Nilai akurasi, presisi, recall, dan F1-score menjadi dasar untuk melepaskan kemampuan model dalam melakukan klasifikasi. Selain nilai numerik, konfusi matriks dan contoh hasil prediksi digunakan untuk melihat pola kesalahan klasifikasi yang terjadi pada model.

Tabel 8
Ringkasan Hasil Tabel

No.	Tahapan	Hasil
1	Dataset	100 citra
2	Kelas	Sehat dan Antraknosa
3	Preprocessing	Resize 224 × 224 piksel dan normalisasi
4	Segmentasi	Otsu Thresholding
5	Model	Convolutional Neural Network (CNN)
6	Accuracy	95,00%
7	Precision	95,92%
8	Recall	94,00%
9	F1-Score	94,95%

Hasil tersebut menjadi dasar untuk melakukan pembahasan lebih lanjut mengenai efektivitas kombinasi Otsu Thresholding dan CNN dalam klasifikasi penyakit antraknosa pada daun cabai. Pembahasan selanjutnya akan menginterpretasikan hasil eksperimen, membandingkan kinerja model dengan penelitian terdahulu, serta membahas faktor-faktor yang dapat mempengaruhi keberhasilan dan kesalahan klasifikasi.

V. DISCUSSION

Berdasarkan hasil penelitian, proses deteksi penyakit antraknosa pada daun cabai dilakukan melalui beberapa tahapan, yaitu preprocessing, segmentasi menggunakan Otsu Thresholding, normalisasi, klasifikasi menggunakan Convolutional Neural Network (CNN), serta evaluasi model. Tahap preprocessing dilakukan dengan mengubah ukuran seluruh citra menjadi 224 × 224 piksel agar memiliki ukuran input yang seragam. Selanjutnya, nilai piksel dinormalisasi dari rentang 0–255 menjadi 0–1. Proses tersebut bertujuan untuk mempersiapkan citra agar lebih sesuai dengan kebutuhan model CNN dan membantu proses pembelajaran berjalan secara konsisten.

Segmentasi menggunakan Otsu Thresholding dilakukan untuk memisahkan objek daun dari latar belakang. Berdasarkan hasil segmentasi, objek daun dapat dipisahkan dari latar belakang terutama pada citra yang memiliki perbedaan intensitas yang cukup jelas. Dengan berkurangnya informasi latar belakang, karakteristik visual daun menjadi lebih terfokus sehingga dapat digunakan sebagai masukan untuk proses klasifikasi. Namun, hasil segmentasi dapat berbeda apabila warna daun dan latar belakang memiliki tingkat intensitas yang hampir sama atau kondisi pencahayaan pada citra tidak merata. Oleh karena itu, kualitas citra menjadi salah satu faktor yang dapat memengaruhi hasil segmentasi dan klasifikasi.

Proses klasifikasi dilakukan menggunakan CNN untuk membedakan dua kelas, yaitu daun sehat dan daun antraknosa. CNN melakukan ekstraksi fitur melalui lapisan convolution sehingga karakteristik visual seperti bentuk, tekstur, pola, dan perubahan warna dapat dipelajari secara otomatis. Hasil ekstraksi fitur kemudian diteruskan melalui pooling, flatten, dan dense layer hingga menghasilkan prediksi kelas. Berdasarkan hasil training yang digunakan, model memperoleh akurasi pelatihan sebesar 98,12% dan akurasi validasi sebesar 95,60%, dengan nilai loss pelatihan sebesar 0,052 dan validation loss sebesar 0,134. Perbedaan antara akurasi training dan validation menunjukkan bahwa model memiliki performa yang lebih tinggi pada data training, tetapi masih mampu mempertahankan performa yang cukup baik pada data validation.

Pada tahap pengujian, model digunakan untuk mengklasifikasikan citra yang tidak digunakan selama proses training. Berdasarkan hasil evaluasi yang digunakan, model memperoleh accuracy sebesar 95,00%, precision sebesar 95,92%, recall sebesar 94,00%, dan F1-score sebesar 94,95%. Nilai accuracy menunjukkan bahwa sebagian besar citra berhasil diklasifikasikan dengan benar. Nilai precision menunjukkan bahwa prediksi terhadap kelas antraknosa memiliki tingkat ketepatan yang cukup tinggi, sedangkan recall menunjukkan bahwa sebagian besar citra antraknosa dapat dikenali oleh model. F1-score yang diperoleh juga menunjukkan adanya keseimbangan antara precision dan recall.

Hasil confusion matrix menunjukkan bahwa masih terdapat beberapa kesalahan klasifikasi. Pada contoh hasil pengujian, terdapat 48 citra yang berhasil diklasifikasikan sebagai daun sehat dengan benar dan 47 citra antraknosa

yang berhasil diklasifikasikan dengan benar. Selain itu, terdapat 2 citra sehat yang diprediksi sebagai antraknosa dan 3 citra antraknosa yang diprediksi sebagai sehat. Kesalahan tersebut dapat disebabkan oleh kemiripan karakteristik visual antara daun sehat dan daun yang mengalami gejala antraknosa, kualitas citra, pencahayaan, latar belakang, maupun tingkat keparahan gejala penyakit.

Secara keseluruhan, kombinasi Otsu Thresholding dan CNN dapat digunakan sebagai pendekatan untuk melakukan klasifikasi citra daun cabai menjadi kelas sehat dan antraknosa. Otsu Thresholding membantu memisahkan objek daun dari latar belakang, sedangkan CNN mempelajari karakteristik visual untuk menentukan kelas citra. Meskipun hasil pengujian menunjukkan performa yang cukup baik, penelitian selanjutnya masih dapat dikembangkan dengan menggunakan dataset yang lebih banyak dan beragam agar model dapat diuji pada kondisi citra yang lebih bervariasi. Pengujian dengan kondisi pencahayaan, latar belakang, posisi daun, dan tingkat keparahan penyakit yang berbeda juga diperlukan untuk mengetahui kemampuan generalisasi model secara lebih luas.

VI. CONCLUSIONS

Berdasarkan penelitian yang telah dilakukan mengenai deteksi penyakit antraknosa pada daun cabai menggunakan metode Otsu Thresholding dan Convolutional Neural Network (CNN), dapat disimpulkan bahwa pengolahan citra digital dapat digunakan sebagai salah satu pendekatan untuk membantu proses identifikasi kondisi daun cabai. Penelitian ini dilakukan melalui beberapa tahapan yang saling berkaitan, mulai dari pengumpulan citra daun cabai, preprocessing, segmentasi menggunakan Otsu Thresholding, normalisasi citra, pembagian dataset, pelatihan model CNN, pengujian, hingga evaluasi model. Rangkaian tahapan tersebut digunakan untuk menghasilkan suatu pendekatan yang mampu membedakan citra daun cabai sehat dengan citra daun yang terindikasi penyakit antraknosa berdasarkan karakteristik visualnya.

Penerapan metode Otsu Thresholding pada penelitian ini digunakan untuk melakukan segmentasi citra dengan memisahkan objek utama berupa daun cabai dari bagian latar belakang. Proses segmentasi dilakukan berdasarkan distribusi intensitas piksel pada citra sehingga diperoleh citra yang lebih berfokus pada bagian objek daun. Tahapan ini penting karena latar belakang pada citra dapat mengandung informasi yang tidak berkaitan dengan kondisi penyakit daun dan berpotensi memengaruhi proses klasifikasi. Dengan adanya segmentasi, citra hasil pengolahan dapat digunakan sebagai masukan yang lebih terarah pada proses klasifikasi menggunakan CNN.

Penggunaan Convolutional Neural Network (CNN) ditujukan untuk mengembangkan model yang mampu melakukan klasifikasi terhadap citra daun cabai. CNN dapat mempelajari karakteristik visual yang terdapat pada citra melalui proses ekstraksi fitur dan pembelajaran selama proses training. Dalam penelitian ini, klasifikasi diarahkan pada dua kondisi, yaitu daun sehat dan daun yang terindikasi penyakit antraknosa. Dengan demikian, penerapan CNN dapat digunakan untuk membantu menentukan kondisi daun berdasarkan pola visual yang dipelajari dari dataset yang tersedia.

Performa model yang dikembangkan kemudian dapat diketahui melalui proses pengujian dan evaluasi. Evaluasi dilakukan menggunakan beberapa metrik, yaitu accuracy, precision, recall, F1-score, dan confusion matrix. Accuracy digunakan untuk mengetahui tingkat ketepatan klasifikasi secara keseluruhan, precision digunakan untuk mengetahui ketepatan hasil prediksi terhadap kelas yang diberikan, recall digunakan untuk mengetahui kemampuan model dalam mengenali data dari kelas tertentu, sedangkan F1-score digunakan untuk melihat keseimbangan antara precision dan recall. Confusion matrix digunakan untuk melihat secara lebih rinci jumlah citra yang berhasil maupun yang mengalami kesalahan klasifikasi pada masing-masing kelas.

Berdasarkan keseluruhan proses tersebut, kombinasi Otsu Thresholding dan CNN dapat digunakan sebagai pendekatan dalam mendukung deteksi dini penyakit antraknosa pada daun cabai berbasis citra. Otsu Thresholding berperan pada tahap segmentasi untuk membantu memisahkan objek daun dari latar belakang, sedangkan CNN berperan pada tahap klasifikasi untuk membedakan daun sehat dan daun yang terindikasi antraknosa. Kombinasi kedua metode tersebut memberikan alur pengolahan yang terstruktur, mulai dari mempersiapkan citra, memisahkan objek yang menjadi fokus penelitian, hingga melakukan klasifikasi berdasarkan karakteristik visual yang terdapat pada citra.

Meskipun demikian, hasil deteksi tetap dipengaruhi oleh kualitas dan karakteristik dataset yang digunakan. Kondisi pencahayaan, posisi daun, latar belakang, kualitas citra, serta tingkat kejelasan gejala antraknosa dapat memengaruhi proses segmentasi maupun klasifikasi. Oleh karena itu, sistem yang dikembangkan perlu diuji menggunakan dataset yang lebih banyak dan lebih beragam agar kemampuan model dalam mengenali kondisi daun dapat diketahui secara lebih menyeluruh. Pengujian pada kondisi lingkungan dan karakteristik citra yang berbeda juga diperlukan untuk mengetahui konsistensi kemampuan metode dalam mendukung proses deteksi penyakit antraknosa pada daun cabai.

Dengan demikian, penelitian ini telah mencapai tujuan utama berupa penerapan Otsu Thresholding untuk segmentasi citra daun cabai dan pengembangan CNN untuk mendeteksi penyakit antraknosa. Evaluasi menggunakan

accuracy, precision, recall, F1-score, dan confusion matrix dapat digunakan sebagai dasar untuk mengetahui performa model yang dihasilkan. Hasil penelitian ini diharapkan dapat menjadi dasar bagi pengembangan sistem deteksi penyakit tanaman berbasis pengolahan citra dan deep learning yang lebih lanjut, khususnya dalam membantu proses identifikasi penyakit antraknosa pada tanaman cabai secara lebih terstruktur dan berbasis teknologi.

Author Contributions: [*Ismawati*]: Konseptualisasi, Metodologi, Penulisan – Draf Asli, Penulisan – Telaah & Penyuntingan, Supervisi. [*Softianto*]: Investigasi, Kurasi Data, Penulisan - Draf Asli.

Semua penulis telah membaca dan menyetujui versi naskah yang telah dipublikasikan.

Pendanaan: -
Ucapan Terima Kasih: -
Konflik Kepentingan: Para penulis menyatakan tidak memiliki konflik kepentingan.
Ketersediaan Data: -
Persetujuan Berdasarkan Informasi ORCID: Tidak tersedia.
Penulis Pertama: https: -
Penulis Kedua: https: -
Penulis Ketiga: -

REFERENCES

[1] H. I. Kim, J. Y. Yoon, dan H. J. Ju, "Diagnosis Anthracnose of Chili Pepper Using Convolutional Neural Networks Based Deep Learning Models," *Plant Pathol. J.*, vol. 41, no. 1, hal. 100–111, Feb 2025, doi: 10.5423/PPJ.OA.11.2024.0178.

[2] N. N. Ahmad Loti, M. R. Mohd Noor, dan S. W. Chang, "Integrated analysis of machine learning and deep learning in chili pest and disease identification," *J. Sci. Food Agric.*, vol. 101, no. 9, hal. 3582–3594, Jul 2021, doi: 10.1002/jsfa.10987.

[3] M. Sibiya dan M. Sumbwanyambe, "Automatic fuzzy logic-based maize common rust disease severity predictions with thresholding and deep learning," *Pathogens*, vol. 10, no. 2, hal. 1–17, 2021, doi: 10.3390/pathogens10020131.

[4] M. A. Restuning Pamuji dan D. Putra Pamungkas, "Segmentasi Citra Daun Bawang Merah Menggunakan Metode Thresholding Otsu," *Nusant. Eng.*, vol. 6, no. 2, hal. 169–174, 2023, doi: 10.29407/noe.v6i2.20553.

[5] M. D. Pratama, R. Gustriansyah, dan E. Purnamasari, "Klasifikasi Penyakit Daun Pisang menggunakan Convolutional Neural Network (CNN)," *J. Teknol. Terpadu*, vol. 10, no. 1, hal. 1–6, 2024, doi: 10.54914/jtt.v10i1.1167.

[6] J. Simangunsong, N. D. Simanjuntak, dan A. A. Matondang, "Penerapan Transfer Learning untuk Klasifikasi Citra Bunga Berbasis Convolutional Neural Network," *J. Minfo Polgan*, vol. 14, no. 1, hal. 1062–1067, 2025, doi: 10.33395/jmp.v14i1.14980.

[7] A. Rahman, M. Salim, dan I. Riadi, "Klasifikasi Citra Spesies Bunga Di Indonesia Berbasis Convolutional Neural Network Menggunakan Teknik Transfer Learning," *J. Softw. Eng. Comput. Intell.*, vol. 2, no. 02, hal. 92–100, 2025, doi: 10.36982/jseci.v2i02.4942.

[8] B. S. Wijaya, R. Munir, dan N. P. Utama, "Segmentasi Awan pada Citra Satelit Multispektral Menggunakan Convolutional Neural Networks," *J. Teknol. Inf. dan Ilmu Komput.*, vol. 12, no. 6, hal. 1251–1260, 2025, doi: 10.25126/jtiik.2025125.

[9] Subhan Bole Boly dan Mutaqin Akbar, "Segmentasi Citra Sel Darah Menggunakan Convolutional Neural Network," *J. RESTIKOM Ris. Tek. Inform. dan Komput.*, vol. 6, no. 2, hal. 390–398, 2024, doi: 10.52005/restikom.v6i2.336.

[10] N. B. Pamungkas dan A. Suhendar, "Penerapan Metode Convolutional Neural Network pada Sistem Klasifikasi Penyakit Tanaman Apel berdasarkan Citra Daun," *Edumatic J. Pendidik. Inform.*, vol. 8, no. 2, hal. 675–684, 2024, doi: 10.29408/edumatic.v8i2.27958.

[11] N. Istiqomah dan M. Murinto, "Klasifikasi Penyakit Tanaman Padi Berbasis Citra Daun Menggunakan Convolutional Neural Network (CNN)," *JSTIE (Jurnal Sarj. Tek. Inform.*, vol. 12, no. 1, hal. 18, 2024, doi: 10.12928/jstie.v12i1.27314.

[12] M. A. R. Mahardika, N. Yudistira, dan A. Ridok, "Sistem Rekognisi Citra Digital Bahasa Isyarat Menggunakan Convolutional Neural Network dan Spatial Transformer," *J. Teknol. Inf. dan Ilmu Komput.*, vol. 11, no. 6, hal. 1159–1168, 2024, doi: 10.25126/jtiik.1078098.

[13] Moh. Heri Susanto, Irwan Budi Santoso, Suhartono, dan Ahmad Fahmi Karami, "Klasifikasi Penyakit Padi Menggunakan Convolutional Neural Network (CNN) Berbasis Citra Daun," *J. Nas. Tek. Elektro dan Teknol. Inf.*, vol. 14, no. 3, hal. 181–189, 2025, doi: 10.22146/jnteti.v14i3.18791.

[14] M. S. Shahab, A. Junaidi, dan A. N. Sihananto, "Klasifikasi Citra Plankton Dengan Algoritma Hibrida Convolutional Neural Network Dan Extreme Learning Machine," *J. Inform. dan Tek. Elektro Terap.*, vol. 12, no. 3S1, 2024, doi: 10.23960/jitet.v12i3s1.5219.

[15] N. Putri Arafa, S. Rahma Basri, R. Ratnasari, dan R. Adi Saputra, "Klasifikasi Penyakit Pada Daun Tanaman Cabai Dengan Pendekatan Artificial Neural Network (Ann)," *JATI (Jurnal Mhs. Tek. Inform.*, vol. 8, no. 6, hal. 12865–12871, 2024, doi: 10.36040/jati.v8i6.12140.

[16] P. A. Azli, M. Minarni, A. Syahrani, G. Y. Swara, dan A. Anisya, "Segmentasi Citra Daun Tomat untuk Klasifikasi Penyakit Tanaman Menggunakan Support Vector Machine (SVM)," *J. Inform. J. Pengemb. IT*, vol. 10, no. 4, hal. 997–1008, 2025, doi: 10.30591/jpit.v10i4.9404.

[17] Fajri Pramana Putra dan Niki Ratama, "Klasifikasi Penyakit Daun Padi Berbasis Android Menggunakan Convolutional Neural Network (Cnn) Dan Transfer Learning Mobilenetv3," *Inform. J. Tek. Inform. dan Multimed.*, vol. 6, no. 1, hal. 288–297, 2026, doi: 10.51903/informatika.v6i1.1622.

[18] N. Sasita, Futri Zalzabilah Ray, M.Fauzanil Wildan A.R., Tantowi Hutagalung, dan Rokhmat Febrianto, "Deep Learning-Based Brain Tumor Classification Using Convolutional Neural Network," *J. Elektro*, vol. 18, no. 1, hal. 20–27, 2025, doi: 10.25170/jurnalelektro.v18i1.6658.

[19] N. K. M. Khalid, N. Jamal, F. Mustafa, N. A. Zambri, M. Syah, dan R. Abdullah, "Solar Power IoT Based Smart Agriculture System Using NodeMCU ESP32," *Penerbit Uthm*, vol. 5, no. 1, hal. 95–102, 2024, [Daring]. Tersedia pada:

https://publisher.uthm.edu.my/periodicals/index.php/peat

[20] Y. Mulyana Prayoga, D. Wahyuni, dan Elisawati, "Deteksi Penyakit Tanaman Cabai Berbasis Deep Learning Menggunakan Convolutional Neural Network Secara Real Time," *J. Unitek*, vol. 18, no. 2, hal. 292–302, 2025, doi: 10.52072/unitek.v18i2.1467.

[21] A. N. Ramadani dan Rujianto Eko Saputro, "Deteksi Dini Katarak Berbasis Citra Mata Menggunakan Metode Deep Learning Convolutional Neural Network (Cnn)," *Rabit J. Teknol. dan Sist. Inf. Univrab*, vol. 11, no. 2, hal. 2882–2891, 2026, doi: 10.36341/rabit.v11i2.7914.

[22] A. Achmadi, B. Akramul Umam, dan A. Anwari, "Identifikasi Penyakit Daun Tembakau Berbasis Pengolahan Citra dengan Metode Convolutional Neural Network (CNN) Dan Metode Transfer Learning," *J. SISKOM-KB (Sistem Komput. dan Kecerdasan Buatan)*, vol. 8, no. 1, hal. 10–16, 2024, doi: 10.47970/siskom-kb.v7i3.654.

[23] M. Gugus Azhari, M. Ajid Husain, dan M. Lutfi, "Transfer Learning Convolutional Neural Network Dengan Arsitektur Efficientnet Untuk Identifikasi Penyakit Daun Cabai," *JATI (Jurnal Mhs. Tek. Inform.*, vol. 7, no. 5, hal. 3662–3666, 2024, doi: 10.36040/jati.v7i5.7791.

[24] L. Mahdiyah, S. Oktamuliani, dan W. L. Putri, "Penerapan Algoritma Deep Learning YOLOv8 pada Platform Roboflow untuk Segmentasi Citra Panoramik," *J. Fis. Unand*, vol. 14, no. 3, hal. 228–234, 2025, doi: 10.25077/jfu.14.3.228-234.2025.

[25] B. Suswati, "Implementasi Convolutional Neural Network pada Klasifikasi Citra Daun Tanaman Hias," *Decod. J. Pendidik. Teknol. Inf.*, vol. 4, no. 2, hal. 554–565, 2024, doi: 10.51454/decode.v4i2.590.

[26] D. Lisnawati dan M. Fachrie, "Klasifikasi Penyakit Daun Alpukat Menggunakan Convolutional Neural Network (Cnn) Berbasis Citra," *JATI (Jurnal Mhs. Tek. Inform.*, vol. 9, no. 6, hal. 10325–10332, 2025, doi: 10.36040/jati.v9i6.16455.

[27] L. febby Olivia, Y. Yuhandri, dan S. Arlis, "Penerapan Deep Learning Menggunakan Metode Convolutional Neural Network dan K-Means dalam Klasterisasi Citra Butiran Pasir," *J. KomtekInfo*, hal. 54–62, 2025, doi: 10.35134/komtekinfo.v12i1.629.

[28] M. Salman, R. Kurniawan, B. Intan, dan B. Santoso, "Deteksi Dini Terhadap Penyakit Tumor Otak Menggunakan Citra Magnetik Resonance Imaging (MRI) dengan Pendekatan Deep Convolutional Neural Network," *J. Ilm. Inform.*, vol. 10, no. 1, hal. 37–41, 2025, doi: 10.35316/jimi.v10i1.37-41.

[29] T. Brian, A. P. Pujiputra, Putri Nur Rahayu, I. F. Augustino, P. Parman, dan I. I. D. Bone, "Segmentasi Citra Pengelasan Kapal Menggunakan Convolutional Neural Network," *SENTRI J. Ris. Ilm.*, vol. 4, no. 10, hal. 2511–2525, 2025, doi: 10.55681/sentri.v4i10.4767.

[30] M. B. Sastramandala, R. N. Sari, dan N. Novrina, "Pemanfaatan Deep Learning menggunakan Convolutional Neural Network Terhadap Penyakit Tuberkulosis melalui Citra Rontgen," *J. Minfo Polgan*, vol. 14, no. 1, hal. 631–642, 2025, doi: 10.33395/jmp.v14i1.14818.

[31] H. Yolanda, L. Hakim, S. Satriansyah, dan T. H. B. Aviani, "Penerapan Convolutional Neural Network Dalam Klasifikasi Daun Tanaman Obat Menggunakan Pendekatan Transfer Learning," *JUSIFOR J. Sist. Inf. dan Inform.*, vol. 4, no. 2, hal. 149–157, 2025, doi: 10.70609/jusifor.v4i2.7056.

[32] R. Adenia, A. E. Minarno, dan Y. Azhar, "Implementasi Convolutional Neural Network Untuk Ekstraksi Fitur Citra Daun Dalam Kasus Deteksi Penyakit Pada Tanaman Mangga Menggunakan Random Forest," *J. Repos.*, vol. 4, no. 4, 2024, doi: 10.22219/repositor.v4i4.32287.

[33] A. D. Septian dan A. Suhendar, "Implementasi Algortima Convolutional Neural Network Untuk Deteksi Penyakit Daun Kentang Menggunakan Citra Digital," *J. Inform. Teknol. dan Sains*, vol. 6, no. 4, hal. 1017–1025, 2024, doi: 10.51401/jinteks.v6i4.4880.

[34] M. D. Erlangga, I. S. Budi, dan M. Mariana, "Efektivitas Kombinasi Bakteri Streptomyces sp Dengan Pestisida Nabati Daun Sirih Dan Daun Kelakai Terhadap Penyakit Antraknosa Pada Cabai Hiyung," *J. Prot. Tanam. Trop.*, vol. 8, no. 1, hal. 1089–1100, 2025, doi: 10.20527/jptt.v8i1.3087.

[35] A. Dwisusilo dan I. Yuadi, "Klasifikasi Penyakit Daun Padi Menggunakan Convolutional Neural Network (CNN) Berbasis Pengolahan Citra Digital untuk Mendukung Ketahanan Pangan Nasional," *J. Ilmu Multidisiplin*, vol. 4, no. 6, hal. 4240–4251, 2026, doi: 10.38035/jim.v4i6.1617.

[36] Rizki Sanria Prasetyo, Agyztia Premana, dan Nur Ariesanto Ramdhan, "Identifikasi Penyakit Daun Mangga Menggunakan Teknik Pengolahan Citra dan Convolutional Neural Network," *J. Publ. Tek. Inform.*, vol. 5, no. 1, hal. 341–353, 2026, doi: 10.55606/jupti.v5i1.6693.

[37] Sulton Ibnu Septiyan, N. Vendyansyah, dan D. Rudhistiar, "Implementasi Convolutional Neural Network Untuk Klasifikasi Penyakit Daun Pisang Menggunakan Citra Digital," *J. Teknol. dan Sist. Tertanam*, vol. 7, no. 1, hal. 49–63, 2026, doi: 10.33365/jtst.v7i1.1155.

[38] Firman Putra Perdana, Bambang Irawan, dan Otong Saeful Bachri, "Klasifikasi Penyakit pada Daun Padi Menggunakan Teknik Pengolahan Citra dan Convolutional Neural Network," *J. Publ. Tek. Inform.*, vol. 5, no. 1, hal. 341–355, 2026, doi: 10.55606/jupti.v5i1.6694.

[39] D. A. Pangestu, O. Q. Aziz, dan C. Crysdian, "Klasifikasi Penyakit pada Tanaman Berdasarkan Citra Daun Menggunakan Metode Convolutional Neural Network," *JISKA (Jurnal Inform. Sunan Kalijaga)*, vol. 10, no. 2, hal. 235–248, 2025, doi: 10.14421/jiska.2025.10.2.235-248.

[40] U. Khaira, I. Weni, dan W. Wilia, "Rancang Bangun Aplikasi Deteksi Penyakit Tanaman Jagung Melalui Citra Daun Berbasis Android Menggunakan Algoritma Convolutional Neural Network," *J. Pepadun*, vol. 5, no. 1, hal. 1–11, 2024, doi: 10.23960/pepadun.v5i1.210.

[41] J. P. Vasconez, J. Delpiano, S. Vougioukas, dan F. Auat Cheein, "Comparison of convolutional neural networks in fruit detection and counting: A comprehensive evaluation," *Comput. Electron. Agric.*, vol. 173, hal. 105348, 2020, doi: 10.1016/j.compag.2020.105348.

[42] F. P. E. Putra, S. M. Dewi, Maugfiroh, dan A. Hamzah, "Jurnal Sistim Informasi dan Teknologi https://jsisfotek.org/index.php Privasi dan Keamanan Penerapan IoT Untuk Kehidupan Sehari-Hari : Tantangan dan Implikasi," *J. Sistim Inf. dan Teknol.*, vol. 5, no. 2, hal. 26–32, 2023, doi: 10.60083.

[43] F. P. E. Putra, U. Ubaidi, M. Mahendra, M. Surur, dan A. Rizki, "4G LTE Network Performance Analysis Provider 3 In Pamekasan Using The G-Nettrack Application," *Brill. Res. Artif. Intell.*, vol. 4, no. 1, hal. 427–433, 2024, doi: 10.47709/brilliance.v4i1.4376.

[44] F. P. E. Putra dan N. Saadah, "Interaktif dan Personalisasi Peningkatan Pembelajaran IoT di Sekolah," *J. Sistim Inf. dan Teknol.*, vol. 5, no. 2, hal. 175–181, 2023, [Daring]. Tersedia pada: http://www.jsisfotek.org/index.php/JSisfotek/article/view/236%0Ahttps://www.jsisfotek.org/index.php/JSisfotek/article/download/236/166

[45] F. P. E. Putra, R. M. Ilhamsyah, S. A. Efendy, dan A. Rizki, "Implementation And Evaluation Of Zerotier-Based Virtual Network For Device Connectivity," *Brill. Res. Artif. Intell.*, vol. 5, no. 1, hal. 281–290, 2025, doi: 10.47709/brilliance.v5i1.5966.

[46] DWI PRASETYANINGSIH, *Sistem Monitoring Suhu, Oksigen Terlarut Dan Ph PadaTanaman Hidroponik Pakcoy BerbasisInternet of Things*. digilib.unila.ac.id, 2025. [Daring]. Tersedia pada: https://digilib.unila.ac.id/89261/

[47] F. P. E. Putra, M. Dafid, dan I. Syafi'i, "Firewall Implementation as a Computer Network Security Strategy for Data Protection," *Brill. Res. Artif. Intell.*, vol. 5, no. 1, hal. 291–297, 2025, doi: 10.47709/brilliance.v5i1.6162.

[48] F. P. E. Putra, U. Ubaidi, R. O. F. Kusuma, A. M. Syam, dan S. A. Efendy, "Effect Of Distance On Wi-Fi Signal Quality In The Home Environment," *Brill. Res. Artif. Intell.*, vol. 4, no. 1, hal. 391–398, 2024, doi: 10.47709/brilliance.v4i1.4319.

[49] Fauzan Prasetyo Eka Putra, Maktsuful Ghummah, Moh. Amrullah, dan Rafli Hidayatullah, "Studi Kinerja Mesh Network untuk Penerapan Internet of Things (IoT) di Lingkungan Perkotaan," 2025, *researchgate.net*. doi: 10.55606/jitek.v5i1.5895.

[50] S. MILDAWATI dan Putri Taqwa Prasetyaningrum, "Analisis Peningkatan Performa Convolutional Neural Network Menggunakan Hyperparameter Tuning Dan Ensemble Learning Pada Klasifikasi Citra Mri Tumor Otak," *Rabit J. Teknol. dan Sist. Inf. Univrab*, vol. 11, no. 2, hal. 4769–4785, 2026, doi: 10.36341/rabit.v11i2.8341.

[51] J. Alfia Afifah Fauzi dan N. Nafi'iyah, "Evaluasi Komparatif Arsitektur Convolutional Neural Network pada Klasifikasi Penyakit Daun Kentang," *J. Algoritm.*, vol. 23, no. 1, 2026, doi: 10.33364/algoritma/v.23-1.3273.

[52] A. Faturohman, D. Anggreani, dan R. Yusliana Bakt, "Model Deep Learning Berbasis Convolutional Neural Network Untuk Identifikasi Stroke Iskemik Pada Citra CT Scan," *J. Pustaka AI (Pusat Akses Kaji. Teknol. Artif. Intell.*, vol. 5, no. 2, hal. 290–297, 2025, doi: 10.55382/jurnalpustakaai.v5i2.1150.

[53] B. D. Prasetyo, E. Widodo, dan D. Ardiatma, "Sistem Monitoring Kualitas Air Sumur Berbasis Iot Dengan Fuzzy Logic Dan Interface Berbasis Web," *Insect (Informatics Secur. J. Tek. Inform.*, vol. 11, no. 1, hal. 55–66, 2025, doi: 10.33506/insect.v11i1.4324.

[54] F. P. E. Putra, U. Ubaidi, R. N. Saputra, F. M. Haris, dan S. N. R. Barokah, "Application of Internet of Things Technology in Monitoring Water Quality in Fishponds," *Brill. Res. Artif. Intell.*, vol. 4, no. 1, hal. 356–361, 2024, doi: 10.47709/brilliance.v4i1.4231.

[55] I. G. N. A. Santika, N. G. A. P. H. Saptarini, I. P. A. Prayudha, dan G. B. Subiksa, "Evaluasi Model Convolutional Neural Network (CNN) dalam Klasifikasi Penyakit Daun Jagung Berbasis Web Menggunakan Citra Digital," *METHOMIKA J. Manaj. Inform. dan Komputerisasi Akunt.*, vol. 10, no. 1, hal. 98–106, 2026, doi: 10.46880/jmika.vol10no1.pp98-106.

[56] M. Y. M. Sekarwati dan N. Nafiiyah, "Analisis Arsitektur Convolutional Neural Network Dan Transfer Learning Dalam Klasifikasi Kualitas Buah," *Rabit J. Teknol. dan Sist. Inf. Univrab*, vol. 11, no. 1, hal. 67–72, 2026, doi: 10.36341/rabit.v11i1.6622.

[57] A. A. Alimi, A. R. Adriansyah, dan P. Prima, "Pengembangan Sistem Deteksi Tuberkulosis pada Citra X-Ray Menggunakan Metode Convolutional Neural Network (CNN) dengan Framework Laravel," *J. Inform. Terpadu*, vol. 10, no. 2, hal. 165–171, 2024, doi: 10.54914/jit.v10i2.1437.

Publisher's Note: Publisher stays neutral with regard to jurisdictional claims in published maps and institutional affiliations.